데이터 수집 및 저장

contents

- Ⅰ. 빅데이터 수집 개요
- 2. 웹크롤링(Web Crawling)
- 3. 정적 웹크롤링 및 저장
- 4. 동적 웹크롤링 및 저장
- 5. 공공 데이터 수집(data.go.kr) 및 저장
- 6. 민간 데이터 수집(Naver 개발자 센터 외) 및 저장

1장 빅데이터 수집 개요

contents

- ▶ 빅데이터 개요
- ▶ 데이터 수집 개요
- ▶ 데이터 수집 방법

BigData Processing Flow

STEPS OF BIG DATA PROCESSING

Data Collection

- Accuracy
- Completeness
- Real-time Data

Data Preprocessing

- Cleansing
- Transformation
- Deduplication
- Normalization

Data Storage

- Scalability
- Redundancy
- Data Retrieval

Data Analysis

- Descriptive Analytics
- Predictive Analytics
- Prescriptive Analytics

Data Visualization

- Clarity
- Interactivity
- Relevance

빅데이터의 정의

- 디지털 환경에서 발생하는 대량의 모든 데이터
- ▶ 대규모 데이터를 저장 관리 분석할 수 있는 하드웨어/소프트웨어 기술, 데이터를 유통 활용하는 모든 프로세스를 포함
- ▶ 빅데이터 플랫폼을 구성하는 하드웨어/소프트웨어/애플리케이션 간의 유기적 순환에 의해 가치를 창출

| 기관 | 정의 | |
|----------|--|--|
| 맥킨지 | 일반적인 데이터베이스 소프트웨어가 수집, 저장, 관리, 분석할 수 있는 범위를 초과하는 대규모의 데이터다. | |
| 가트너 | 향상된 시사점과 더 나은 의사결정을 위해 사용되는 것으로 비용 효율이 높고 혁신적이며 대용량 고속 및 다양성을 가지는 정보 자산이다. | |
| 위키피디아 | 기존 데이터베이스 관리 도구의 수집, 저장, 관리, 분석 역량을 넘어서는 대량의 정형 또는 비 정형 데이터셋 및 이러한 데이터로부터 가치를 추출하고 결과를 분석하는 기술이다. | |
| 국가전략위원회 | 대용량 데이터를 활용 및 분석하여 가치 있는 정보를 추출하고 생성된 지식을 바탕으로 능동 적으로 대응하거나 변화를 예측하기 위한 정보화 기술이다. | |
| 삼성경제연구소 | 기존의 관리 및 분석 체계로는 감당할 수 없을 정도의 거대한 데이터 집합으로 대규모 데이터와 관계된 기술 및 도구(수집, 저장, 검색, 공유, 분석, 시각화 등)를 모두 포함한다. | |
| 한국정보화진흥원 | 저장, 관리, 분석할 수 있는 범위를 초과하는 규모의 데이터와 이것을 저장, 관리, 분석할 수 있는 하드웨어 및 소프트웨어 기술, 데이터를 유통 및 활용하는 과정을 통틀어 나타낸다. 즉, 빅데이터를 구성하는 하드웨어, 소프트웨어 그리고 이를 포괄하는 모든 프로세스를 의미하는 거대 플랫폼이다. | |





빅데이터의 분류

- > 정형 데이터
 - ▶ **일정한 규칙으로 체계적으로 정리된** 것으로 그 자체로 해석이 가능하여 바로 활용할 수 있음
- ▶ 반정형 데이터
 - ▶ 고정된 필드에 저장되어 있지는 않지만 XML, HTML 등의 메타데이터와 스키마를 포함하는 것으로 파일 형태로 저장
- ▶ 비정형 데이터
 - ▶ 고정된 필드나 스키마가 없는 것
 - ▶ 스마트 기기에서 페이스북, 트위터, 유튜브 등으로 생성되는 소셜 데이터
 - ▶ IoT 환경에서 생성되는 위치 정보나 센서 데이터와 같은 사물 데이터 등



▶ 빅데이터의 특징(데이터 측면)

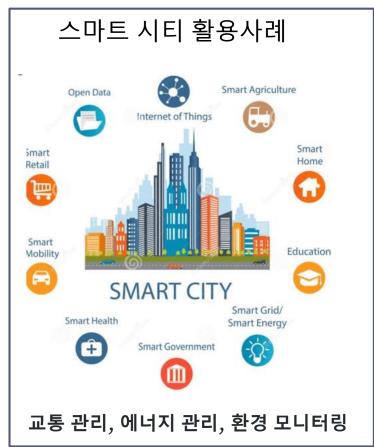
- ▶ 빅데이터의 특징을 3V로 일컬어지는 규모(Volume), 다양성(Variety), 속도(Velocity)로 나타냄
- ▶ 빅데이터를 통한 가치 창출이 중요해지면서 정확성(veracity)과 가치(value)를 추가한 5V로 나타냄

| 구분 | 특징 | 설명 |
|---|-----|--|
| 1차 특징 | 규모 | • ICT 기술의 발전으로 디지털 정보량이 기하급수적으로 폭증하여 제타바이트 시대로 진입 |
| | 다양성 | • 데이터의 종류 증가: 로그 기록, 소셜/위치/소비/현실 데이터 등 • 데이터의 유형 다양화: 텍스트 외에 멀티미디어 등의 비정형 데이터 증가 |
| | 속도 | 센서, 모니터링 등의 시물 정보와 스트리밍 등의 실시간 정보가 증가하면서 데이터의 생성 및 이동(유통) 속도 증가 대규모 데이터를 처리하고 가치 있는 정보를 활용하기 위한 데이터 처리 및 분석 속도 증가 |
| 정확성 • 방대한 데이터를 기반으로 분석을 수행하므로 정확성 향상 | | • 방대한 데이터를 기반으로 분석을 수행하므로 정확성 향상 |
| 추가 특징 | 가치 | • 빅데이터 분석으로 도출된 최종 결과물이 문제 해결을 위한 통찰력을 제공하므로 새로 운 가치 창출 가능 |



빅데이터 활용









고객 행동 분석, 시장 트렌드 예측, 개인화 마케팅

▶ 빅데이터 처리 과정별 기술

| 과정 | 영역 | 설명 |
|------------|--|---------------------------------------|
| 생성 | 내부데이터 | 데이터베이스, 파일 관리 시스템 등 |
| 00 | 외부데이터 | 인터넷으로 연결된 파일, 멀티 미디어, 스트림 |
| 수집 | 크롤링 | 검색 엔진의 로봇, HTML 크롤링 소프트웨어를 사용한 데이터 수집 |
| ТВ | ETL (Extration, Transformation, Loading) | 소스 데이터의 추출, 전송, 변환, 적재 |
| | NOSQL 데이터 베이스 | 비정형데이터 관리 |
| 저장 | 스토리지 Storage | 빅데이터 저장, 저장소 |
| | 서버 Server | 초경량 서버 |
| 처리 | 맵리듀스 MapReduce | 데이터 추출 |
| AI-I | 프로세싱 Processing | 다중 업무 처리 |
| | NLP Netural Language Processing | 자연어 처리 |
| 분석 | 기계학습 Machine Learning | 머신러닝, 딥러닝을 이용한 데이터의 패턴 인식 |
| | 직렬화 Serialization | 데이터 간의 순서화 |
| 표현 | 시각화 Visualization | 데이터를 도표나 그래픽 등으로 표현 |
| т <u>г</u> | 획득 Acquisition | 데이터의 획득, 재해석 |



▶ 데이터 수집 정의

- ▶ '서비스 활용에 필요한 데이터를 시스템의 내부 혹은 외부에서 주기성을 갖고 필요한 형태로 수집하는 활동'
- ▶ 다양한 유형의 데이터(정형, 반정형, 비정형)를 수집하는 것
- ▶ 데이터 수집 기술은 빅데이터 제공 **서비스의 품질을 결정하는 중요한 기술**
 - ▶ 데이터가 존재해도 수집할 수 있는 기술이 미비하면 빅데이터 관련 서비스에 대한 품질을 기대하기 어렵다.



수집 데이터 형태에 따른 분류

- > 정형 데이터
 - ▶ 관계형 데이터베이스 시스템의 테이블과 같이 고정된 컬럼에 저장되는 데이터
 - ▶ 데이터의 스키마를 지원
 - ▶ 예: RDBMS의 테이블들, 스프레드시트 데이터
- ▶ 반정형 데이터
 - ▶ 데이터 내부에 정형 데이터의 스키마에 해당되는 메타데이터를 가지고 있음
 - ▶ 파일 형태로 저장
 - ▶ 예: URL 형태로 존재(HTML), 오픈 API 형태로 제공(XML, JSON), 로그 형태 로 제공(웹 로그, IOT에서 제공하는 센서 데이터)
- ▶ 비정형 데이터
 - ▶ 데이터 세트가 아닌 하나의 데이터가 수집 데이터로 객체화 됨
 - ▶ 언어 분석이 가능한 텍스트 데이터, 이미지, 동영상 같은 멀티미디어 데이터
 - ▶ 예: 이진 파일 형태(동영상, 이미지), 스크립트 파일 형태(소셜 데이터의 텍스트)

▶ 수집 난이도

| 형태 | 특징 | 난이도 |
|---------|--|-----|
| 정형 데이터 | 내부 시스템인 경우가 대부분이라 수집이 쉽다. 파일 형태의 스프레드시트라도 내 부에 형식을 가지고 있어 처리가 쉬운 편이다. | 하 |
| 반정형 데이터 | 보통 API 형태로 제공되기 때문에 데이터 처리 기술이 요구 된다. | 중 |
| 비정형 데이터 | 텍스트 마이닝 혹은 파일일 경우 파일을 데이터 형태로 파싱해야 하기 때문에 수집 데이터 처리가 어렵다. | 상 |

▶ 데이터처리 아키텍처 구성 난이도

| 형태 | 특징 | 난이도 |
|---------|--|-----|
| 정형 데이터 | CRUD가 일어나는 일반적인 아키텍처 구조로 이루어져 있다. 하 | |
| 반정형 데이터 | 데이터의 메타구조를 해석해 정형 데이터 형태로 바꿀 수 있는 아키텍처 구조를 수 정해야 한다. | 중 |
| 비정형 데이터 | 텍스트나 파일을 파싱해 메타구조를 갖는 데이터의 셋형태로 바꾸고 정형 데이터 형태의 구조로 만들 수 있도록 아키텍처 구조를 수정해야 한다. | 상 |

▶ 데이터의 잠재적 가치

| 형태 | 특징 | 잠재가치 |
|---------|---|------|
| 정형 데이터 | 내부 데이터의 특성상 현실적 가치의 한계상 활용측면에서 잠재적 가치는 상대적으로 낮다. | 보통 |
| 반정형 데이터 | 데이터의 제공자가 선별해 제공하는 데이터로 잠재적 가치는 정형 데이터 보다 높다. | 높음 |
| 비정형 데이터 | 수집주체에 의해 데이터에 대한 분석이 선행되었기 때문에 목적론적 데이터 특징이 가장 잘 나타나는 데이터이다. 그렇기 때문에 일단 수집이 가능하면 수집주체에게 는 가장 높은 잠재적 가치를 제공한다. | 매우높음 |



수집 위치에 따른 데이터 분류

- ▶ 내부 데이터
 - ▶ 수집 원천 데이터의 데이터 저장소가 내부 시스템에 있는 데이터
 - ▶ **데이터 제공자**와 상호 협약에 의한 **의사 소통 가능**
 - ▶ 데이터 수집 주기 및 방법은 데이터 제공자(or 기관)와의 협약을 통해 제공받음
 - ▶ **수집 실패**한 데이터에 대한 **재 수집 구현 가능**

▶ 외부 데이터

- ▶ 수집 원천 데이터의 데이터 저장소가 외부 시스템에 있는 데이터
- ▶ 데이터 제공자와 협약 된 관계가 아니면 **상호 의사소통이 불가능**
- ▶ 데이터 수집을 위해 수집 주기 및 방법에 관한 분석이 필요
- ▶ **외부 데이터의 인터페이스방법**은 수집할 항목을 분석해 수집 시스템을 설계
- ▶ 협약이 되지않은 시스템의 경우 수집 실패에 대안을 마련 필요
- ▶ 가능한 데이터의 **전처리 과정 없이 원본 데이터를 수집** 후, 수집 시스템에서 처리를 할 수 있도록 인터페이스를 설계하는 것이 바람직함.



▶ 수집 난이도

| 위치 | 특징 | 난이도 |
|----|--|-----|
| 내부 | 데이터의 저장소가 내부에 있으므로 해당 소스 데이터 담당자와 의사소통이 원활하기 때문에 수집난이도가 외부데이터와 비교해 낮다. | 하 |
| 외부 | 외부 소스의 경우 해당 소스 데이터 담당자와 의사소통이 어려워 상대적으로 수집 난이도가 높다 | 상 |

▶ 데이터 처리 아키텍처 구성 난이도

| 위치 | 특징 | 난이도 |
|----|--|-----|
| 내부 | 대부분 정형 데이터이므로 일반적인 CRUD처리 아키텍처와 같은 구성이 가능하다. | 하 |
| 외부 | 대부분 비정형, 반정형 데이터 형태로 일반적인 아키텍처 구성에 반정형, 비정형 데 이터를 처리할 수 있는 아키텍처를 추가해야 한다. | 상 |

▶ 데이터잠재적가치

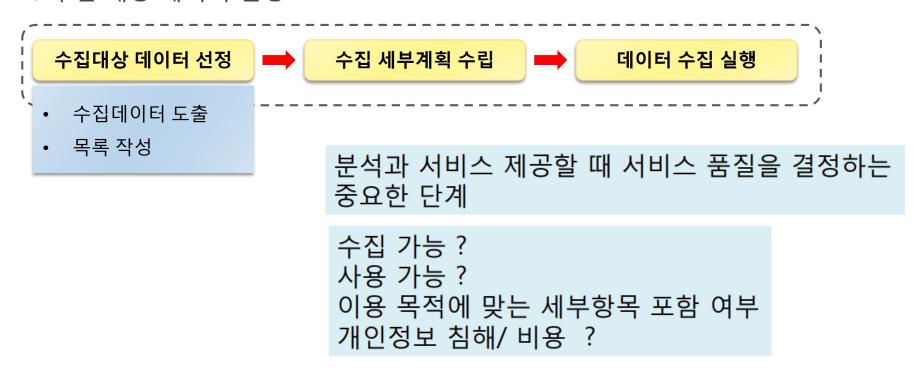
| 위치 | 특징 | 난이도 |
|----|---|-----|
| 내부 | 내부 데이터의 특성과 현실적 가치의 한계상 활용 측면에서 잠재적 가치는 상대적으로 낮다. | 보통 |
| 외부 | 데이터의 제공자가 선별해 제공하는 데이터나 수집주체에 대한 분석이 이루어진 후 수집을 하는 데이터이기 때문에 데이터의 목적론적 특징이 가장 잘 나타나는 데이 터이다. 그렇기 때문에 내부 데이터와 비교할 경우 상대적으로 잠재적 가치가 높다. | 높음 |

수집방버

- ▶ HTTP 수집
 - ▶ 크롤링(Crawling): 텍스트 정보를 가져오는 수집 기술
 - ▶ Open API 수집기술: 웹을 운영하는 운영주체가 정보를 제공하는 수집 기술
- ▶ 로그/센서 수집
 - ▶ 로그수집기술: 데이터 처리 에이전트의 구별을 통해 로그 수집 기술
 - ▶ 센서데이터수집기술:실시간처리가 주를 이루는 머신 정보 수집 기술
- ▶ DBMS 수집
 - ▶ DBMS 수집은 DB에 직접 연결해 데이터를 수집
- ▶ FTP 수집
 - ▶ 대용량 파일을 수집하기 위하여 클라이언트 서버간 연결 및 파일전송, FTP 보안 기능이 제공

데이터 수집 처리 단계

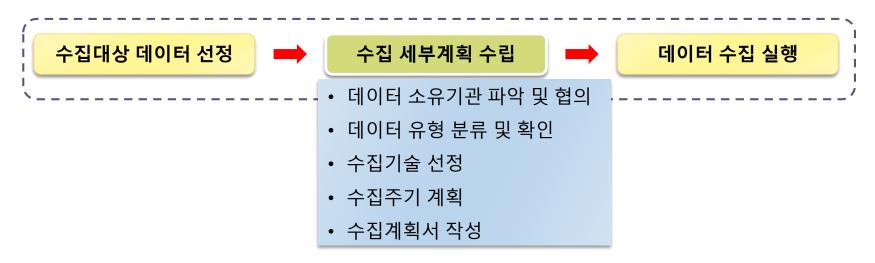
I. 수집 대상 데이터 선정





▶ 데이터 수집 처리 단계

2. 수집 세부계획 수립





- ▶ 데이터 수집 처리 단계
 - 3. 데이터 수집 실행



- 능동적 데이터 수집
 - 데이터 소유 주체가 수집을 원하는 자에게 능동적 제공
 - 예: 생산관련로그, 설문조사
- VS 수동적데이터수집
 - 데이터 소유 주체가 웹 페이지에 데이터 공개, 데이터를 원하는 자가 데이터 수집
 - 예: 웹 로봇, 웹 크롤러

▶ 데이터 수집 실행

- ▶ 내부 데이터 수집
 - ▶ 내부 파일시스템, DB, 센서
 - ▶ ETL(Extraction, Transformation, Loading)

▶ 외부 데이터 수집

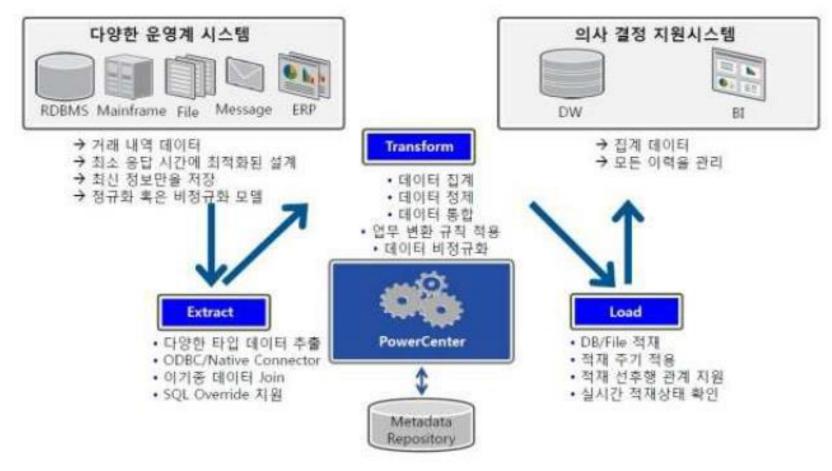
- ▶ 인터넷으로 연결된 외부에서 데이터 수집
- Crawling Engine
- ▶ 예: SNS, UCC, 온라인쇼핑, 검색 등

- ▶ 데이터 수집 실행(빅데이터 수집을 위한 변환 및 통합)
 - ▶ 변환은 정제를 포함
 - ▶ 비정형 데이터 정제, 정형 데이터에서 측정값이 빠져 있거나, 형식이 다르거나, 내용 자체가 틀린 데이터를 고침

| ●● 빅데이터 수집을 위한 변환 및 통합 ●● | | |
|--|--|--|
| ETL(Extraction, Transformation, Load) | 메인프레임, ERP, CRM, Flat file, Excel 파일 등으로부터 데이터를 추출하여 목표하는 저장소의 데이터 형태로 변형한 후 목표 저장소(DW)에 저장 | |
| 비정형 → 정형 | 비정형 데이터는 비구조적 데이터 저장소에 저장하거나 어느 정도 구조적인 형태로 변형하여 저장 ex) Scribe, Flume, chuckwa 등 오픈 소스 솔루션 | |
| 레거시 데이터와 비정형 데이터간의 통합 | 데이터를 분석하기 위해서는 수집된 정형의 레거시 데이터와 비정형 데이터간의 통합이 필요 • Sqoop: RDBMS와 HDFS간의 데이터를 연결해 주는 기능으로 SQL 데이터를 Haoop으로 로드하는 도구 | |



▶ 데이터 수집 시스템



▶ 웹크롤링과 웹 스크래핑

웹 크롤링

웹 페이지의 하이퍼링크를 순회하면서
 웹 페이지를 다운로드하는 작업

<u>웹</u> 스크래핑

- 다운로드한 웹 페이지에서 필요한 콘텐츠를 추출하는 작업
- 웹 페이지를 구성하고 있는 HTML 태그의 콘텐츠나 속성의 값을 읽는 작업

```
(td)빨강 머리 앤(/td)
태그의 콘텐츠
(a href="https://www.python.org/")파이썬(/a)
태그의 속성값
```

- ▶ 웹 크롤링과 웹 스크래핑
 - URL(Uniform Resource Locator)
 - 네트워크 상에서 자원이 어디 있는지를 알려주기 위한 규약
 - 컴퓨터 네트워크와 검색 메커니즘에서의 자원의 위치를 지정하는 문자열



URI(Uniform Resource Identity)

- 웹 사이트에 요청하고자 하는 대상의 패스정보와 파일명으로 구성
- 파일명이 생략되면 디폴트로 index.html 사용

▶ 공공 데이터(www.data.go.kr)

공공데이터

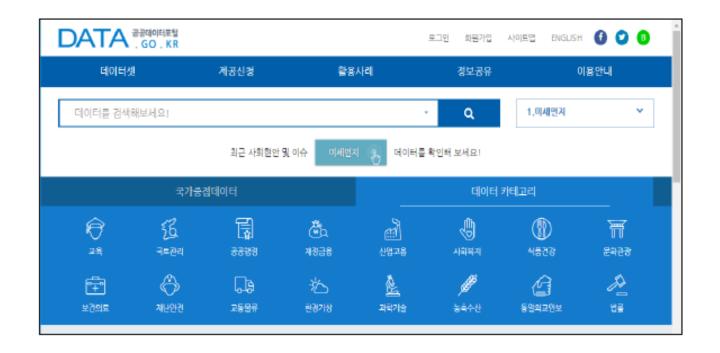
 공공기관이 전자적으로 생성 또는 취득하여 관리하고 있는 모든 데이터베이스(DB), 전자화된 파일

공공데이터 개방

 공공기관이 이용자에게 정보를 재활용할수 있도록 제공하고, 제공받은 정보를 상업적·비영리적으로 이용할 권한 부여

- 보유하고 있는 공공데이터를 적극적으로 개방하여 국민과 공유함으로써 소통과 협력을 확대하기 위해 공공 데이터 정책 추진
- ▶ 2013년 7월 공공 데이터 법을 제정하고 공공 데이터 개방을 I0월부터 시행

- ▶ 공공 데이터
 - ▶ 공공 데이터 포털(https://www.data.go.kr)
 - ▶ 공공기관이 생성 또는 취득하여 관리하고 있는 공공 데이터를 한 곳에서 제공하는 통합 창구



▶ 공공 데이터

- ▶ 서울 열린 데이터 광장(<u>https://data.seoul.go.kr/</u>)
 - ▶ 열린 시정 3.0에 의해 공공 데이터를 민간에 개방하고 소통함으로써 공익성, 업무 효율성, 투명성을 높이고 시민의 자발적 참여로 새로운 서비스와 공공의가치를 창출할 수 있도록 하는 서비스
- ▶ 국가통계포털(KOSIS, Korean Statistical Information Service)
 - ▶ 국내, 국제, 북한의 주요 통계를 한곳에 모아 이용자가 원하는 통계를 한번에 찾을 수 있도록 통계청이 제공하는 One-Stop 통계 서비스
- ▶ 부산 공공 데이터 포털(https://data.busan.go.kr)
- ▶ 부산관광통계(https://bta.or.kr/mcboard/mn_list.php?mnid=bta&mncd=bta6)

SNS(Social Network Service)

소셜 네트워킹 서비스(Social Networking Service)

- 사용자 간의 자유로운 의사소통과 정보 공유, 인맥 확대 등을 통해 사회적 관계를 생성하고 강화해주는 온라인 플랫폼
- 최근 스마트폰 이용자의 증가와 무선인터넷 서비스의 확장과 더불어 SNS의 이용자 또한 급증하고 있음





SNS

OPEN API

- 인터넷 이용자가 웹 검색 결과 및 사용자 화면 등을 제공 받는데 그치지 않고 직접 응용 프로그램과 서비스를 개발할 수 있도록 공개된 개발자를 위한 인터 페이스
- ▶ 대부분의 SNS 사이트들은 개발자로 등록하고 인증키를 받아 제공되는 API 사용
- 트위터: https://developer.twitter.com/
- 네이버블로그검색: https://developers.naver.com/docs/search/blog/
- 네이버뉴스검색: https://developers.naver.com/docs/search/news/

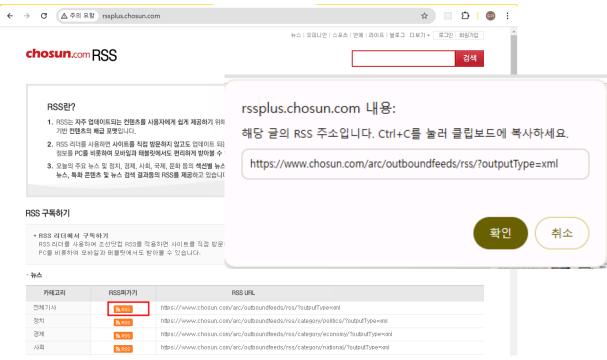
RSS

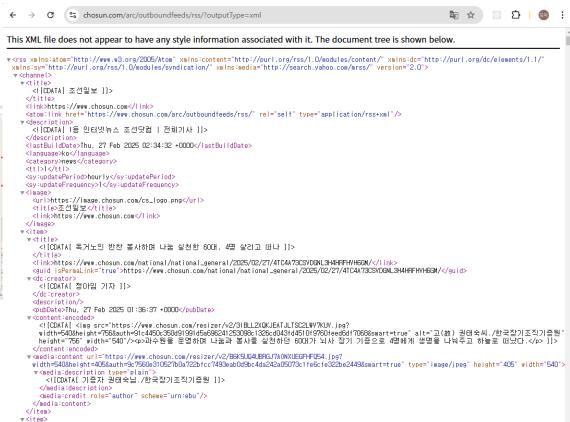
- RSS(Really Simple Syndication/Rich Site Summary)
 - 뉴스나 블로그와 같이 콘텐츠 업데이트가 자주 일어나는 웹사이트에서 업데이트 된정보를 정해진 규격의 XML 형식으로 자동화하여 사용자에게 제공하기 위한 서비스



▶ RSS

▶ 조선일보 RSS(<u>http://rssplus.chosun.com/</u>)





▼<title>